

Serverless Hybrid Document OCR, Parsing & Technical Translation Platform on AWS

Đề tài: Nền tảng Bóc tách, OCR Lai & Dịch thuật Tài liệu Kỹ thuật Đa tầng trên Điện toán Đám mây AWS

Học viên: Lâm Quang Huy	Mã sinh viên: 0212267	Cơ sở đào tạo: ĐH Xây dựng Hà Nội (HUCE)
Lớp chuyên ngành: 67CS - CNTT	AWS Account ID: 677994024390	Account Name: huylam (ap-southeast-1)
Live ALB URL: huylam-ocr-alb-1284818160.ap-southeast-1.elb.amazonaws.com	Workshop Site: Lamhuy0489.github.io/workshop	GitHub: github.com/Lamhuy0489/aws

1. Tóm Tắt Dự Án (Executive Summary)

Serverless Hybrid Document OCR, Parsing & Technical Translation Platform on AWS là nền tảng điện toán đám mây cấp doanh nghiệp được thiết kế nhằm giải quyết bài toán số hóa, bóc tách cấu trúc và chuyển ngữ các tài liệu kỹ thuật phức tạp (hồ sơ thiết kế, hợp đồng, báo cáo tài chính, bài báo khoa học PDF/ảnh scan đa ngôn ngữ) với độ chính xác cao, thời gian phản hồi tức thì và chi phí vận hành tối ưu tuyệt đối (0.00 USD trong suốt kỳ thực tập). Hệ thống vận hành thực tế qua Application Load Balancer Multi-AZ công khai Internet kết nối máy chủ EC2 Gunicorn, tích hợp dịch vụ lưu trữ bền vững S3, cơ sở dữ liệu NoSQL DynamoDB On-Demand, quản trị cấu hình bảo mật AWS Systems Manager Parameter Store, và xác thực danh tính liên kết Amazon Cognito với Google OAuth 2.0.

Ba Trụ Cột Đột Phá Cốt Lõi Của Giải Pháp:

- Two-Stage Hybrid Engine:** Tầng 1 Fast-Path Native (PyMuPDF) trích xuất trực tiếp văn bản số trong 0.1s - 0.3s/trang với chi phí 0 USD (xử lý 80%+ tài liệu văn phòng). Tầng 2 Selective OCR tự động định tuyến trang scan/ảnh tới cụm GPU Qwen2.5-VL hoặc Google Gemini Flash với cơ chế tự phục hồi Failover an toàn.
- Markdown-Preserving Technical Translation Engine:** Dịch thuật tài liệu kỹ thuật bảo toàn 100% cú pháp Markdown, bảng biểu số liệu, công thức toán LaTeX.
- Multi-Format Export Engine:** Xuất bản đa định dạng sang Markdown (.md), Microsoft Word (.docx chuẩn quốc tế), và PDF in ấn chuẩn A4.

Điểm Nhấn Vận Hành Thực Tế & Nghiệm Thu:

- Live Production URL:** <http://huylam-ocr-alb-1284818160.ap-southeast-1.elb.amazonaws.com> (ALB Listener HTTP 80 → Target Group cổng 5000).
- Cổng Đăng Nhập Doanh Nghiệp:** Tích hợp SSO Google OAuth 2.0 qua Amazon Cognito User Pool (50,000 MAU Always Free).
- Bảo Mật Phân Tầng:** Security Group Chaining cô lập máy chủ EC2 khỏi Internet; quản trị Shell từ xa qua SSM Session Manager (zero open SSH ports).
- FinOps Zero Cost:** Chi phí vận hành toàn bộ vòng đời thực tập được kiểm soát ở mức 0.00 USD.

2. Kiến Trúc Hạ Tầng Đám Mây AWS (Enterprise Three-Tier Architecture)

Hệ thống tuân thủ nghiêm ngặt chuẩn **AWS Well-Architected Framework**, kết hợp giữa mô hình mạng doanh nghiệp 3 tầng (Three-Tier Enterprise Cloud Networking) và kiến trúc phi máy chủ hướng sự kiện (Event-Driven Serverless):

Tầng Kiến Trúc	Tài Nguyên AWS	Định Danh Kỹ Thuật (ID / ARN)	Vai Trò & Cấu Hình An Ninh
Phân phối & Cân bằng tải	Application Load Balancer (ALB)	huylam-ocr-alb	Multi-AZ (1a & 1b), Listener HTTP:80, Health check /login (Healthy 1/1).
Chuỗi an ninh phân tầng	Security Group Chaining	huylam-alb-sg → huylam-web-sg	ALB SG mở cổng 80 cho Internet. Web SG chỉ mở cổng 5000 cho nguồn từ ALB SG, cô lập EC2.
Máy chủ ứng dụng	Amazon EC2 (t2.micro)	i-0566e1eedaacea52d (huylam-ocr-web-server)	Amazon Linux 2023, IP 10.0.8.15. Chạy daemon systemd Gunicorn cổng 5000. Quản trị qua SSM.
Lưu trữ đối tượng	Amazon S3 Bucket	huylam-ocr-documents-ap-sout heast-1	Độ bền 99.999999999%. Phân cấp thư mục uploads/ và outputs/. Mã hóa SSE-S3.
Cơ sở dữ liệu trạng thái	Amazon DynamoDB	document_processing_jobs	NoSQL On-Demand (PAY_PER_REQUEST). Partition Key job_id, Sort Key created_at.
Quản trị cấu hình bảo mật	SSM Parameter Store	/huylam-ocr/config	Loại SecureString mã hóa KMS. Quản trị API key tập trung, không hardcode mã nguồn.
Quản lý danh tính & SSO	Amazon Cognito User Pool	huylam-ocr-user-pool (User pool - qp0rmn)	Federated IdP Google OAuth 2.0. Miền kc4iwg.auth.ap-southeast-1.amazoncognito.com.
Tự động hóa phi máy chủ	AWS Lambda (Python 3.11)	huylam-ocr-processor	S3 Event Notification kích hoạt Lambda tạo bản ghi DynamoDB tức thì trong 214 ms.

3. Động Cơ Xử Lý Bóc Tách Lai Đa Tầng (Two-Stage Hybrid Engine)

Nền tảng triển khai giải thuật lai phân tầng nhằm tối ưu hóa triệt để hiệu năng và kinh tế đám mây:

- Tầng 1 - Fast-Path Native Extraction:** Đối với tài liệu định dạng PDF có sẵn lớp ký tự (chiếm hơn 80% tài liệu kỹ thuật, báo cáo, hợp đồng), PyMuPDF trực tiếp bóc tách văn bản, tọa độ bảng và phân đoạn trang chỉ mất **0.1s - 0.3s/trang** với chi phí 0.00 USD.
- Tầng 2 - Selective Vision OCR:** Chỉ những trang có mật độ văn bản thấp hơn ngưỡng hoặc là ảnh quét scan mới được kích hoạt bộ điều phối OCR. Hệ thống tích hợp mô hình thị giác AI Kaggle Qwen2.5-VL (\$0) mở qua Cloudflare Tunnel, tự động chuyển đổi dự phòng (Failover) sang Google Gemini 3.6 Flash / Flash Lite kèm thuật toán xoay vòng API Keys tự động (Key Tour Manager) và tùy chọn AWS Bedrock Nova.
- Chuyển ngữ bảo toàn Markdown & Đa định dạng:** Hệ thống dịch thuật chuyên ngành bảo toàn 100% cú pháp tiêu đề, ma trận bảng biểu số liệu, công thức toán học, và hỗ trợ xuất bản tức thì sang tệp Microsoft Word (.docx) và PDF in ấn.

4. Bảng Số Liệu Đo Kiểm Thực Nghiệm (Benchmark Empirical Metrics)

Hạng Mục Kiểm Thử	Mẫu Dữ Liệu	Động Cơ Thực Thi	Thời Gian Xử Lý	Chi Phí Vận Hành	Đánh Giá Kết Quả
Bóc tách văn bản số	cv.pdf (1 trang)	Fast-Path Native	0.31 giây	0.00 USD	Hoàn hảo, tức thì
Bóc tách bài báo KH	28_Bai_Bao.pdf (11 trang)	Fast-Path Native	3.07 giây (~0.28s/trang)	0.00 USD	Bảo toàn bảng biểu
Bóc tách ảnh quét scan	Ảnh scan biểu mẫu	Kaggle Qwen2.5-VL / Gemini	2.54 giây	0.00 USD (Free Tier)	Tiếng Việt có dấu 100%
Tùy chọn AWS Native	Ảnh scan hóa đơn	Amazon Bedrock (Nova)	4.61s - 6.99s	Pay-as-you-go	Bóc tách chính xác
Dịch thuật bảo toàn MD	cv.pdf (Anh → Việt)	Gemini Flash Translator	2.80 giây	0.00 USD (Free Tier)	Giữ 100% format bảng
Xuất Word (.docx)	Tệp kết quả dịch	DocxExporter Module	0.15 giây	0.00 USD	Tệp 38.2 KB mở chuẩn
Kích hoạt S3 → Lambda	Upload vào uploads/	Lambda (Python 3.11)	214 - 257 ms	0.00 USD (Free Tier)	Tạo record DynamoDB
Độ trễ ALB Production	Public DNS Ingress	Application Load Balancer	15 - 25 ms	0.00 USD (Free Tier)	HTTP 200 OK mượt mà

5. Lộ Trình Triển Khai 12 Tuần Thực Tập (Worklog Milestones)

Giai Đoạn / Tuần	Mục Tiêu Trọng Tâm	Dịch Vụ AWS & Sản Phẩm Đạt Được
Tuần 1 - 2 (Khởi đầu)	Thiết lập môi trường, an toàn tài khoản AWS, quản trị chi phí	Kích hoạt MFA Root, IAM Users/Groups, cấu hình AWS Budgets khóa chi phí, cài đặt AWS CLI v2.
Tuần 3 - 4 (Hạ tầng cốt lõi)	Mạng ảo VPC phân tầng, máy chủ ảo EC2, lưu trữ Amazon S3	Khởi tạo VPC, Public/Private Subnets, Internet Gateway, IAM Role S3 Full Access, kết nối máy chủ Linux.
Tuần 5 - 6 (Giám sát & Mã hóa)	Hạ tầng dạng mã (IaC), giám sát CloudWatch và mã hóa KMS	Tự động hóa với AWS CloudFormation, cấu hình CloudWatch Alarms, thiết lập khóa mã hóa AWS KMS.
Tuần 7 - 8 (Containerization)	Đóng gói ứng dụng Docker Container và lưu trữ Amazon ECR	Dockerfile OCI Container đa tầng trên Python 3.11, kho ECR Repository lưu trữ và kiểm soát phiên bản.
Tuần 9 - 10 (Serverless & Dữ liệu)	Thiết kế Serverless, DynamoDB On-Demand, SSM Parameter Store	Bucket S3 với CORS an toàn, bảng DynamoDB document_processing_jobs, tham số mã hóa /huylam-ocr/config.
Tuần 11 (Event-Driven)	Đo kiểm Benchmark thực nghiệm, S3 Event Notification & Lambda	Kiến trúc hướng sự kiện tự động S3 → Lambda → DynamoDB → CloudWatch phản hồi trong 214 ms.
Tuần 12 (Production Live)	Triển khai kiến trúc mạng 3 tầng, cân bằng tải ALB, cấp link thật	ALB Multi-AZ công khai Internet, chuỗi Security Group Chaining, Unicorn systemd, tích hợp Cognito Google SSO.

6. Quản Trị Tài Chính FinOps & Cam Kết Tốt Nghiệp

Chiến Lược Tối Ưu Chi Phí 0.00 USD (FinOps Governance): Toàn bộ các dịch vụ cốt lõi đều được thiết kế tận dụng triệt để hạn ngạch AWS Free Tier và cơ chế Serverless On-Demand: DynamoDB không tính cước khi nhàn rỗi, Lambda trong giới hạn 1 triệu request miễn phí/tháng, Cognito miễn phí tới 50,000 MAU. Tầng bóc tách Fast-Path bản địa triệt tiêu 80%+ chi phí GPU suy luận thị giác. Học viên có kế hoạch xóa ALB và dừng máy chủ EC2 khi hoàn tất phiên nghiệm thu để đảm bảo không phát sinh chi phí ngoài ý muốn.

Kết luận: Đề tài đã hoàn thành xuất sắc 100% mục tiêu đề ra, khẳng định năng lực làm chủ kiến trúc điện toán đám mây AWS, kết hợp hài hòa giữa kỹ năng hạ tầng DevOps, mô hình trí tuệ nhân tạo thị giác AI và văn hóa kỹ thuật chuẩn mực.